

Tutoría de Inteligencia artificial:

Economía grado A-2026

Integrantes:

- Kira Carrasco
- Andrés Ledesma
- Carlos Yépez
- Alfredo Villavicencio

1. Introducción

El objetivo del proyecto es predecir la supervivencia de pasajeros del Titanic mediante un problema de clasificación binaria. La variable objetivo es Survived, donde 1 representa supervivencia y 0 no supervivencia. El análisis se desarrolló sobre 891 observaciones, con una partición estratificada de 80% entrenamiento y 20% prueba para conservar la proporción de clases.

La propuesta supera el primer clasificador visto en clase porque integra un flujo reproducible con Pipeline, ColumnTransformer, validación cruzada, búsqueda de hiperparámetros, comparación de cuatro algoritmos y evaluación con métricas más completas que la exactitud. El uso de Pipeline permite encadenar transformaciones y estimador final en un solo objeto, lo que reduce el riesgo de data leakage durante entrenamiento y validación (Pedregosa et al., 2011).

2. Feature engineering

Se crearon variables nuevas dentro del Pipeline para que las transformaciones se ajusten solo con los datos de entrenamiento.

La construcción de variables se orientó a representar dimensiones familiares, económicas y sociales del viaje:

FamilySize:

$SibSp + Parch + 1$. Representa el tamaño del grupo familiar o de acompañamiento. La literatura sobre el Titanic ha tratado el acompañamiento familiar como un factor social relevante de supervivencia; por tanto, se incluye para que el modelo evalúe empíricamente ese patrón (Frey et al., 2011; Gupta, 2018).

IsAlone

Identifica si el pasajero viajaba solo. Esta variable resume la información de FamilySize en una categoría interpretable y permite capturar diferencias entre pasajeros aislados y acompañados.

Fare_per_person:

$Fare / FamilySize$. Aproxima la tarifa individual dentro de un grupo familiar; puede reflejar mejor la posición económica que la tarifa total cuando varios pasajeros comparten ticket.

CabinKnown y Deck.

Indican si la cabina fue registrada y la cubierta aproximada. La clase, la ubicación y la disponibilidad del registro están vinculadas con diferencias sociales y de acceso durante la evacuación (Frey et al., 2011).

Title

Extrae el título social del nombre, como Mr, Mrs, Miss o Master. Esta variable resume información de género, edad aproximada y estatus social; los estudios de desastres marítimos muestran que género, edad y normas sociales pueden modificar las probabilidades de supervivencia (Elinder y Erixson, 2012).

3. Modelos comparados

Se compararon cuatro modelos bajo el mismo conjunto de entrenamiento/prueba y el mismo preprocesamiento. La Regresión Logística se usó como línea base por ser un clasificador clásico para respuesta binaria (Cox, 1958). El Árbol de Decisión se incluyó por su interpretabilidad y por representar reglas no lineales (Quinlan, 1986). Random Forest fue considerado por combinar múltiples árboles y reducir la inestabilidad de un árbol individual (Breiman, 2001). Gradient Boosting se seleccionó por su capacidad de construir modelos secuenciales que corrigen errores previos y suelen lograr alto desempeño predictivo (Friedman, 2001).

4. Resultados

La selección de hiperparámetros se aplicó a Random Forest y Gradient Boosting mediante GridSearchCV con cv=5 y scoring=AUC-ROC. Se eligió AUC-ROC porque evalúa la capacidad del modelo para separar sobrevivientes y no sobrevivientes a partir de probabilidades, no solo mediante una clasificación final fija.


Modelo optimizado	Mejores hiperparámetros	Mejor AUC-ROC promedio CV
Gradient Boosting	learning_rate = 0.05; max_depth = 2; min_samples_leaf = 1; n_estimators = 100	0.8811
Random Forest	max_depth = None; min_samples_leaf = 4; min_samples_split = 2; n_estimators = 200	0.8783

La tabla siguiente resume la evaluación sobre el conjunto de prueba. El mejor desempeño general fue obtenido por la Regresión Logística, con un AUC-ROC de 0.8581 y un F1 macro de 0.8146. Esto indica que, en esta partición, el modelo lineal presentó mejor capacidad de generalización que los ensambles más complejos.

Modelo	Accuracy	Precision Macro	Recall Macro	F1 Macro	AUC-ROC
Logistic Regression	0.8268	0.8202	0.8105	0.8146	0.858103
Gradient Boosting Optimizado	0.7933	0.7821	0.7805	0.7813	0.848814
Random Forest Optimizado	0.7933	0.7867	0.7697	0.7758	0.848485
Decision Tree	0.7486	0.7378	0.7468	0.7403	0.733202

4.1 Matriz de confusión y curva ROC

La matriz de confusión permite observar los aciertos y errores del mejor modelo. La curva ROC compara la sensibilidad frente a la tasa de falsos positivos en distintos umbrales. En conjunto, ambas visualizaciones confirman que la Regresión Logística logra el mayor AUC en prueba, aunque todavía existen errores de clasificación asociados a la información limitada disponible en el dataset.



4.2 Análisis de overfitting e importancia de variables

El análisis de overfitting compara el AUC de entrenamiento con el AUC promedio de validación cruzada. El Árbol de Decisión presenta la mayor brecha entre entrenamiento y validación cruzada, con una diferencia de 0.2543, lo que evidencia un fuerte ajuste al conjunto de entrenamiento. Random Forest Optimizado también muestra una brecha relevante de 0.0803, mientras que Gradient Boosting Optimizado presenta una diferencia menor de 0.0361. La


Regresión Logística obtiene la brecha más baja, 0.0131, por lo que muestra el comportamiento más estable entre entrenamiento y validación.

Modelo	Train AUC-ROC	CV AUC-ROC Promedio	CV AUC-ROC Desv. Est.	Diferencia Train - CV
Decision Tree	0.9995	0.7452	0.0413	0.2543
Random Forest Optimizado	0.9585	0.8783	0.0190	0.0803
Gradient Boosting Optimizado	0.9172	0.8811	0.0176	0.0361
Logistic Regression	0.8743	0.8612	0.0181	0.0131

Nota: Los modelos Random forest y Gradient Boosting se encuentran optimizados

Los resultados muestran que las variables asociadas al perfil demográfico del pasajero fueron las más influyentes, especialmente `who_man`, `who_woman` y `who_child`. Esto es coherente con el contexto histórico del Titanic, donde las diferencias por género, edad y normas sociales tuvieron un papel relevante en las probabilidades de supervivencia.

También aparecen como variables relevantes `pclass`, `sibsp`, `CabinKnown`, `FamilySize` e `IsAlone_custom`, lo cual sugiere que la clase del boleto, el acompañamiento familiar y la disponibilidad de información de cabina aportaron información útil al modelo.



5. Conclusiones

Se recomienda la Regresión Logística como modelo final porque obtuvo el mayor AUC-ROC en prueba, con 0.8581, el mayor F1 macro, con 0.8146, y la menor brecha entre entrenamiento y validación cruzada, con 0.0131. Aunque Gradient Boosting Optimizado obtuvo el mayor AUC promedio durante la validación cruzada, su desempeño en prueba fue ligeramente inferior y presentó una brecha entrenamiento-validación más alta. La principal limitación del análisis es el tamaño reducido del dataset y la presencia de variables faltantes, especialmente `Cabin`. Con más tiempo se podrían probar validaciones repetidas, calibración de probabilidades, permutation importance agrupada por variable original y una búsqueda más amplia de hiperparámetros.

REFERENCIAS BIBLIOGRÁFICAS

Breiman, L. (2001). Random Forests. *Machine Learning*, 45, 5-32.

<https://doi.org/10.1023/A:1010933404324>

Cox, D. R. (1958). The regression analysis of binary sequences. *Journal of the Royal Statistical Society: Series B*, 20, 215-232. <https://doi.org/10.1111/j.2517-6161.1958.tb00292.x>

Elinder, M., & Erixson, O. (2012). Gender, social norms, and survival in maritime disasters. *PNAS*, 109(33), 13220-13224. <https://doi.org/10.1073/pnas.1207156109>

Frey, B. S., Savage, D. A., & Torgler, B. (2011). Behavior under extreme conditions: The Titanic disaster. *Journal of Economic Perspectives*, 25(1), 209-222. <https://doi.org/10.1257/jep.25.1.209>

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 1189-1232. <https://doi.org/10.1214/aos/1013203451>

Gupta, K. (2018). Surviving the Titanic tragedy: A sociological study using statistical analysis. *Sciéndo*, 21(1), 86-93.

Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

Quinlan, J. R. (1986). Induction of decision trees. *Machine Learning*, 1, 81-106.

<https://doi.org/10.1007/BF00116251>